

National Tsing Hua University

1130IEEM 513600

Deep Learning and Industrial Applications

Homework 2

Name: 王昀萱

Student ID: 113030502

1. Select 2 hyper-parameters of the artificial neural network used in Lab 2 and set 3 different values for each. Perform experiments to compare the effects of varying these hyper-parameters on the loss and accuracy metrics across the training, validation, and test datasets. Present your findings with appropriate tables.

在超參數組合中，我選擇了batch size 與 hidden units兩個超參數進行實驗，將learning rate 固定使用0.001，並且將每個超參數設定 3 組不同的值（batch size：8、16、32；hidden units：64、128、256），總共進行 9 組實驗，去比較與觀察各組模型在訓練集、驗證集與測試集上的表現。

batch_size	8	16	32						
hidden_units	64	128	256						
	LR	Batch Size	Hidden Uni	Train acc	Train loss	Val acc	Val loss	Test acc	Test loss
1	0.01	8	64	87.30	0.34	75.31	0.47	74.19	0.45
2	0.01	16	64	84.13	0.38	83.06	0.36	77.42	0.49
3	0.01	32	64	78.31	0.45	81.48	0.46	70.96	0.61
4	0.01	8	128	83.07	0.38	88.89	0.35	74.19	0.52
5	0.01	16	128	88.36	0.30	74.07	0.54	80.65	0.53
6	0.01	32	128	85.19	0.35	77.78	0.48	77.42	0.57
7	0.01	8	256	88.89	0.31	76.54	0.48	83.87	0.40
8	0.01	16	256	85.19	0.32	82.71	0.44	80.64	0.54
9	0.01	32	256	86.24	0.37	75.31	0.75	74.19	0.81

2. Based on your experiments in Question 1, analyze the outcomes. What differences do you observe with the changes in hyper-parameters? Discuss whether these adjustments contributed to improvements in model performance, you can use plots to support your points.

在實驗結果中，可以看到 batch size 與 hidden units 對模型表現都有明顯影響，batch size較小時(8)，有更好的效果，可能是因為更新權重的頻率較高，不過，在某些組合中的效果不一定最好，並且由於資料訓練數量並不多，反映出有 overfitting 的可能。而在hidden units中，較大的 hidden units 能提升模型容量，增加準確率。在綜觀這次測試中，表現最佳為 batch size = 8、hidden units = 256，其測試準確率達 83.87%，且測試損失最低為 0.4。

3. In Lab 2, you may have noticed a discrepancy in accuracy between the training and test datasets. What do you think causes this occurrence? Discuss potential reasons for the gap in accuracy.

我認為 Train 跟 Test 的 Accuracy 有差異的其中一原因是因為 overfitting所導致，當模型在訓練時可能學習到過多的 noise 或細節所導致的。當 batch size 過小、訓練過久時可能就會導致 overfitting 的狀況。如果要改善的話可以去測試到最佳的 batch size 數或是增加資料及等等，去改善此狀況。

4. Discuss methodologies for selecting relevant features in a tabular dataset for machine learning models. Highlight the importance of feature selection and how it can impact model performance. You are encouraged to consult external resources to support your arguments. Please cite any sources you refer to.

在表格型的dataset中，如果在特徵選擇上沒有處理好，可能會造成訓練模型時的效果不佳，所以在訓練前尋找到關鍵的features 是相當重要的，而在選擇特徵方法中可以用以下的方式：

- Filter：如皮爾森相關係數、卡方檢定。
- Wrapper：如遞迴特徵消除（RFE），直接用模型評估每組特徵的效能。
- Embedded：如 L1 正則化或決策樹特徵重要性。

Reference:

[Chandrashekar, G., & Sahin, F. \(2014\). A survey on feature selection methods. Computers & Electrical Engineering, 40\(1\), 16-28.](#)

5. While artificial neural networks (ANNs) are versatile, they may not always be the most efficient choice for handling tabular data. Identify and describe an alternative deep learning model that is better suited for tabular datasets. Explain the rationale behind its design specifically for tabular data, including its key features and advantages. Ensure you to reference any external sources you consult.

ANN在處理表格式dataset時，可能會因為ANN無法有效去處理特徵間的互動與異質性，所以表現不一定良好，而本篇所說明的**FT-Transformer**就是一種專門針對表格型資料所設計的深度學習模型，它基於 Transformer 架構，可以同時處理連續與類別型變數，透過Attention 機制去學習特徵間的關聯性。可以避免特徵編碼錯誤與資訊流失等問題，較 ANN 在準確率與穩定性上有更好的效果。

Reference:

Gorishniy, Y., Rubachev, I., Khrulkov, V., & Babenko, A. (2021). Revisiting Deep Learning Models for Tabular Data. NeurIPS. <https://arxiv.org/abs/2106.11959>